

TRABAJO PRÁCTICO N.º 2

Métodos no supervisados aplicados a asalariados de la EPH

Cuarto trimestre de 2024 y 2025

Grupo 1- Embarbe Estefania –

Repositorio de GitHub: https://github.com/embarbeestefania-code/Taller_Programacion_EPH

1. Objetivo, datos y construcción de variables

El objetivo es evaluar si los asalariados formales e informales constituyen grupos naturalmente diferenciados cuando se consideran simultáneamente características demográficas, educativas, familiares y laborales. Se aplican PCA, K-means, clustering jerárquico y K-modes. La informalidad no se utiliza para formar los grupos: se incorpora posteriormente para evaluar su correspondencia con los patrones identificados.

Se emplean los registros individuales de la Encuesta Permanente de Hogares del cuarto trimestre de 2024 y 2025. El universo principal comprende asalariados (*CAT_OCUP* = 3) con información válida sobre descuento jubilatorio: formal si *PP07H* = 1 e informal si *PP07H* = 2. Los ingresos de 2024 se expresan a precios promedio del cuarto trimestre de 2025.

Variable	Construcción
<i>edad2</i>	Cuadrado de la edad declarada.
<i>educ</i>	Años de educación a partir de CH12, CH13 y CH14.
<i>horastrab</i>	PP3E_TOT + PP3F_TOT; códigos especiales y valores > 168 se trataron como faltantes.
<i>nhogar</i>	Cantidad de miembros por CODUSU, NRO_HOGAR y COMPONENTE.

Muestra analítica

Período	Formales	Informales	Total	% informal
2024T4	9727	5565	15292	36,4%
2025T4	8815	5128	13943	36,8%
Total	18542	10693	29235	36,6%


Las muestras de casos completos difieren según el método: 18.077 observaciones para PCA y K-means; una submuestra reproducible de 2.000 casos para el dendrograma; y 21.013 casos para K-modes. La estadística descriptiva completa de las variables limpias del TP1 y de las nuevas variables se presenta en el Apéndice A.

Variable	2024T4	2025T4
Educación (años)	12,02	11,96
Horas trabajadas	37,25	37,43
Integrantes del hogar	3,54	3,52

Los promedios son estables entre períodos. La edad media de los ocupados pasa de 41,3 a 41,9 años; la educación se mantiene próxima a 12 años y las horas semanales alrededor de 37. La tabla completa informa observaciones, media, desvío, mínimo, percentiles 25, 50 y 75, y máximo.

2. Matrices de correlación

Se calcularon matrices de correlación de Pearson separadas para 2024T4 y 2025T4. La informalidad presenta una asociación alta y negativa con el tamaño del establecimiento, moderada y negativa con el ingreso principal y la educación, y asociaciones bajas o moderadas con las restantes variables. Estos resultados son descriptivos y no implican causalidad.




Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

La estructura es prácticamente estable: el mayor cambio absoluto entre coeficientes es 0,026. Entre los predictores se destaca la correlación de aproximadamente 0,99 entre edad y edad², esperable porque una variable es una transformación determinística de la otra. Fuera de esa relación, predominan correlaciones bajas o moderadas; por lo tanto, la información multivariada no puede resumirse en una única dimensión.

3. Análisis de componentes principales


El PCA se estimó sobre siete variables estandarizadas: edad, edad², educación, horas trabajadas, integrantes del hogar, ingreso principal y tamaño del establecimiento. Los dos primeros componentes explican 53,91% de la varianza total.

3. PCA: scores, loadings y varianza explicada



Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

En el plano PC1-PC2 existe una superposición considerable entre formales e informales; por lo tanto, el PCA no produce una separación binaria. Sin embargo, los informales se concentran con mayor frecuencia en valores negativos de PC1. Los centroides son (0,468; 0,285) para formales y (-1,014; -0,617) para informales. Se identificaron 91 observaciones extremas mediante el percentil 99,5 de la distancia al origen; se conservaron porque pueden representar combinaciones laborales inusuales y no necesariamente errores.




Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

Compone nte	Varianza individual	Acumulada	Interpretación
PC1	31,74%	31,74%	Ciclo de vida y consolidación laboral
PC2	22,17%	53,91%	Capital humano y calidad del puesto
PC3	15,89%	69,80%	Dimensión adicional
PC4	12,68%	82,48%	Completa gran parte de la heterogeneidad

PC1 está determinado principalmente por edad, edad², ingreso y tamaño del establecimiento. PC2 combina positivamente educación, ingreso y tamaño del establecimiento, y negativamente edad y edad². La distribución de la varianza es coherente con las correlaciones: la redundancia edad-edad² se concentra en un componente, pero las restantes variables aportan dimensiones diferenciadas.

4. Clustering numérico y jerárquico

4.1 K-means




Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

Clúste r	Casos	% formal	% informal	Perfil
0	10004	55,0%	45,0%	Más joven, menor ingreso y hogares mayores
1	8073	85,1%	14,9%	Mayor edad, ingreso y tamaño del establecimiento

Con $k = 2$ y $n_{init} = 20$, K-means no reproduce la división formal/informal: $ARI = 0,065$ y $NMI = 0,083$. El algoritmo distingue perfiles asociados al ciclo de vida y a la consolidación laboral, no dos categorías equivalentes a la formalidad. La inercia se calculó para $k = 1, \dots, 40$. El codo es gradual; se adopta $k = 8$ como solución parsimoniosa dentro de un rango razonable de 8 a 10 grupos.

4.2 Clustering jerárquico




Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

El dendrograma de Ward se construyó sobre una muestra aleatoria reproducible de 2.000 asalariados. La altura representa la disimilitud a la que se fusionan los grupos. Un corte alrededor de distancia 48 identifica tres ramas principales: inserción relativamente precaria (52,2% informal), situación intermedia (25,6%) e inserción consolidada (7,6%).

5. K-modes, conclusiones

K-modes se aplicó a cuatro variables binarias relevantes del TP1 -sexo, educación secundaria completa, cobertura médica y establecimiento de hasta cinco personas- y a edad², educación, horas trabajadas y tamaño del hogar categorizadas. La variable informal se excluyó del entrenamiento.



Fuente: elaboración propia en base a EPH-INDEC, 4T2024 y 4T2025.

Cl.	Peso	% informal	Perfil modal resumido
0	45,8%	20,2%	Varones 35-44; educación media; jornada estándar
1	11,7%	60,0%	Mujeres jóvenes; hogares grandes; jornada extensa
2	11,1%	89,2%	Varones jóvenes; baja educación; sin cobertura; microestablecimientos
3	21,5%	17,4%	Mujeres 45-59; educación superior; jornada reducida
4	9,9%	18,2%	Mujeres jóvenes; alta educación; hogares pequeños

Con k = 2, K-modes tampoco reproduce la informalidad (ARI = -0,017; NMI = 0,008). La curva de costo no presenta un quiebre único y sugiere entre cuatro y seis grupos; se selecciona k = 5. A diferencia de K-means, la estructura categórica requiere menos perfiles. Los clústeres 1 y 2 reúnen 22,8% de la muestra, pero concentran aproximadamente 53,4% de los informales. El promedio de informalidad de esta muestra es 31,8%, inferior al 36,6% general porque K-modes utiliza únicamente casos completos.

Conclusión general

Los métodos no supervisados muestran que la heterogeneidad laboral es más compleja que una división estricta entre formalidad e informalidad (Binaria). La informalidad se asocia sistemáticamente con menores ingresos, menor educación, falta de cobertura médica y establecimientos pequeños, pero estas características se combinan de manera diversa.

Limitaciones y uso de IA

Los algoritmos se estimaron sobre casos completos y sin ponderadores muestrales; describen patrones de la muestra y no estimaciones poblacionales. Microsoft Copilot fue especialmente útil para revisar sintaxis, detectar errores en la construcción de variables y ordenar la implementación de PCA y clustering. También facilitó una primera interpretación de gráficos e indicadores. Su aporte fue menos efectivo para seleccionar el número de clústeres, porque el método del codo exige inspección visual y no ofrece una solución única; por ello, las sugerencias fueron contrastadas con la consigna, los materiales de clase y las salidas obtenidas.

Tiempo total aproximado dedicado: 8hs

Apéndice A. Estadística descriptiva completa - 2024T4

Variables numéricas limpias del TP1 y nuevas variables del TP2. Los ingresos de 2024 se expresan a precios promedio de 2025T4.

Variable	N	Media	SD	Min	P25	P50	P75	Max
Sexo (CH04)	21.132	1,45	0,50	1,00	1,00	1,00	2,00	2,00
Edad (CH06)	21.132	41,31	13,13	11,00	31,00	40,00	51,00	92,00
Estado conyugal (CH07)	21.132	2,92	1,69	1,00	1,00	2,00	5,00	5,00
Cobertura médica (CH08)	21.111	2,10	1,97	1,00	1,00	1,00	4,00	123,00
Nivel educativo	21.132	4,19	1,38	1,00	3,00	4,00	5,00	7,00
Condición de actividad	21.132	1,00	0,00	1,00	1,00	1,00	1,00	1,00
Categoría ocupacional	21.132	2,70	0,54	1,00	2,00	3,00	3,00	4,00
Tipo de empleo	21.116	1,43	0,50	1,00	1,00	1,00	2,00	2,00
Sector laboral	20.275	1,38	0,61	1,00	1,00	1,00	2,00	3,00
Tamaño del establecimiento	17.014	5,41	3,65	1,00	2,00	6,00	8,00	12,00
Ingreso ocupación principal	16.857	827.213	806.431	0,00	328.375	656.750	1.050.800	19.702.500
Ingreso total individual	16.466	939.312	877.449	0,00	420.320	774.965	1.182.150	21.672.750
Región	21.132	34,83	15,64	1,00	40,00	42,00	43,00	44,00
Aglomerado	21.132	23,25	16,88	2,00	12,00	23,00	32,00	93,00
Relación de parentesco	21.132	2,02	1,52	1,00	1,00	2,00	3,00	10,00
Tipo de establecimiento	21.132	1,80	0,43	1,00	2,00	2,00	2,00	3,00
Descuento jubilatorio	15.292	1,36	0,48	1,00	1,00	1,00	2,00	2,00
Aporte jubilatorio propio	5505,00	1,87	0,33	1,00	2,00	2,00	2,00	2,00
Edad al cuadrado	21.132	1878,64	1154,25	121,00	961,00	1600,00	2601,00	8464,00
Años de educación	20.896	12,02	3,61	0,00	10,00	12,00	15,00	22,00
Horas trabajadas	21.119	37,25	16,73	0,00	25,00	40,00	48,00	154,00
Integrantes del hogar	21.132	3,54	1,79	1,00	2,00	3,00	4,00	19,00

Apéndice A. Estadística descriptiva completa - 2025T4

Variables numéricas limpias del TP1 y nuevas variables del TP2.

Variable	N	Media	SD	Min	P25	P50	P75	Max
Sexo (CH04)	19.698	1,45	0,50	1,00	1,00	1,00	2,00	2,00
Edad (CH06)	19.698	41,86	13,29	12,00	31,00	41,00	52,00	100,00
Estado conyugal (CH07)	19.697	2,91	1,68	1,00	1,00	2,00	5,00	5,00
Cobertura médica (CH08)	19.666	2,09	1,73	1,00	1,00	1,00	4,00	23,00
Nivel educativo	19.698	4,17	1,38	1,00	3,00	4,00	5,00	7,00
Condición de actividad	19.698	1,00	0,00	1,00	1,00	1,00	1,00	1,00
Categoría ocupacional	19.698	2,68	0,55	1,00	2,00	3,00	3,00	4,00
Tipo de empleo	19.688	1,44	0,50	1,00	1,00	1,00	2,00	2,00
Sector laboral	18.948	1,39	0,62	1,00	1,00	1,00	2,00	3,00
Tamaño del establecimiento	15.662	5,22	3,66	1,00	1,00	5,00	8,00	12,00
Ingreso ocupación principal	15.784	917.209	909.163	0,00	400.000	800.000	1.200.000	30.000.000
Ingreso total individual	15.384	1.040.595	1.010.776	0,00	500.000	800.000	1.300.000	30.000.000
Región	19.698	35,05	15,45	1,00	40,00	42,00	43,00	44,00
Aglomerado	19.698	22,86	16,55	2,00	10,00	22,00	32,00	93,00
Relación de parentesco	19.698	2,03	1,51	1,00	1,00	2,00	3,00	10,00
Tipo de establecimiento	19.698	1,80	0,42	1,00	2,00	2,00	2,00	3,00
Descuento jubilatorio	13.943	1,37	0,48	1,00	1,00	1,00	2,00	2,00
Aporte jubilatorio propio	5061,00	1,87	0,34	1,00	2,00	2,00	2,00	2,00
Edad al cuadrado	19.698	1928,69	1179,41	144,00	961,00	1681,00	2704,00	10.000
Años de educación	19.430	11,96	3,61	0,00	10,00	12,00	15,00	21,00
Horas trabajadas	19.689	37,43	16,88	0,00	25,00	40,00	48,00	168,00
Integrantes del hogar	19.698	3,52	1,75	1,00	2,00	3,00	4,00	16,00

Apéndice B. Detalles metodológicos y perfiles

B.1 Categorización de variables para K-modes

Variable	Categorías
Edad²	Hasta 24; 25-34; 35-44; 45-59; 60 o más
Educación	Hasta 6; 7-9; 10-12; 13-15; 16-17; 18 o más años
Horas trabajadas	0; 1-19; 20-34; 35-45; 46-60; más de 60 horas
Tamaño del hogar	1; 2; 3-4; 5 o más integrantes

B.2 Variables binarias utilizadas

Variable	Definición
mujer	Sexo declarado: mujer / no mujer.
secundario_completo_o_mas	Educación acumulada igual o superior a 12 años.
con_cobertura_medica	Cobertura por obra social, prepaga o servicio de emergencia.
empresa_hasta_5	Establecimiento de hasta cinco personas frente a establecimientos mayores.

La variable binaria 'asalariado' creada en el TP1 no se incorporó a K-modes porque el universo analizado está restringido a asalariados y, por lo tanto, no aporta variación.

B.3 Loadings de los dos primeros componentes

Variable	PC1	PC2
Edad	0,89	-0,45
Edad²	0,87	-0,48
Ingreso principal	0,52	0,54
Tamaño del establecimiento	0,46	0,51
Miembros del hogar	-0,35	-0,32
Años de educación	0,26	0,65
Horas trabajadas	0,08	0,26

Apéndice C. Todos los prompts de IA utilizados

Herramienta utilizada: Microsoft Copilot.

Prompt 1. Continuidad con el TP1

El TP2 continúa el análisis de la EPH realizado en el TP1 sobre asalariados formales e informales. ¿Qué partes del código de limpieza y construcción de la muestra debe conservarse y qué variables nuevas deben incorporarse?

Prompt 2. Construcción de variables

Ayúdame a construir en Python las variables edad al cuadrado, años de educación, horas totales trabajadas y número de integrantes del hogar, considerando los códigos especiales de la EPH.

Prompt 3. Matrices de correlación

¿Cómo puedo construir matrices de correlación separadas para 2024 y 2025 entre informalidad, edad, educación, horas trabajadas, tamaño del hogar, ingreso y tamaño del establecimiento? Explica cómo interpretar los signos y la intensidad.

Prompt 4. PCA

Explicame de forma sencilla cómo aplicar PCA con variables estandarizadas, obtener scores, loadings, varianza explicada y un biplot. La informalidad no debe utilizarse para estimar los componentes, sino únicamente para comparar visualmente los resultados.

Prompt 5. K-means

Aplica K-means con k igual a 2 y n_init igual a 20 sobre las variables numéricas estandarizadas. ¿Cómo comparo los clústeres obtenidos con la clasificación formal e informal y cómo interpreto el Adjusted Rand Index?

Prompt 6. Método del codo

¿Cómo se aplica el método del codo para seleccionar un número razonable de clústeres? Explica por qué la elección es visual y cómo justificar un rango cuando el quiebre de la curva no es completamente nítido.

Prompt 7. Clustering jerárquico

Ayúdame a construir e interpretar un dendrograma mediante el método de Ward. ¿Qué representa la altura de las fusiones y cómo se selecciona un punto de corte?

Prompt 8. K-modes

Explicame cómo implementar K-modes utilizando variables binarias y variables numéricas categorizadas. La variable informal debe excluirse del entrenamiento y utilizarse después para evaluar la composición de los clústeres.