

Persistencia y predicción de la informalidad laboral en la EPH

Clasificación supervisada con modelos Logit, 4T2024–4T2025

Grupo 1 — Embarbe Estefanía

Repositorio GitHub: https://github.com/embarbeestefania-code/Taller_Programacion_EPH/tree/main/TP3

Resumen

Este trabajo estudia la predicción de informalidad laboral entre asalariados de la EPH-INDEC utilizando el cuarto trimestre de 2024 como muestra de entrenamiento y 2025 como período de evaluación. Se estiman dos modelos Logit: un modelo base con edad, educación, horas trabajadas, tamaño del hogar y sexo, y una especificación longitudinal que incorpora la condición de informalidad del año previo, siguiendo a Maurizio y Monsalvo (2021). La submuestra longitudinal muestra elevada persistencia: 83% de quienes eran informales en 2024 continúa en esa condición en 2025. El Modelo 1 alcanza $AUC=0,782$ y $recall=0,489$; el modelo con estado previo alcanza $AUC=0,928$ y $recall=0,850$ en la evaluación solicitada, aunque esta última contiene un componente de ajuste dentro de muestra. Los resultados resaltan el valor predictivo de la trayectoria laboral y la importancia de evaluar los errores de clasificación según el objetivo de política.

1. Datos y estrategia de validación (Sección A)

Se utilizan las bases usuarias individuales de la EPH-INDEC del IV trimestre de 2024 (46.860 registros) y 2025 (43.703). Se retiene la población ocupada ($ESTADO=1$) y se define el universo clasificable sobre asalariados ($CAT_OCUP=3$): $informal=1$ cuando no se efectúan descuentos jubilatorios ($PP07H=2$) y $formal=0$ cuando sí se efectúan ($PP07H=1$). La muestra modelable reúne 15.292 asalariados en 2024T4 —36,4% informales— y 13.943 en 2025T4 —36,8%—.

La matriz X incluye edad, $edad^2$, años de educación, horas trabajadas, integrantes del hogar y la dummy mujer. Educación se conserva como variable continua para evitar redundancia con dummies de nivel educativo. CODUSU, NRO_HOGAR y COMPONENTE se utilizan exclusivamente para vincular individuos entre años y se eliminan antes de estimar. Tras exigir casos completos quedan 15.104 observaciones en 2024 y 13.743 en 2025.

Nota metodológica sobre cobertura médica. La dummy de cobertura genera cuasi-separación: entre quienes no declaran cobertura, alrededor de 99,7% son informales. Dado su fuerte solapamiento conceptual con la protección social que define el target, se excluye de la especificación principal para evitar que domine la clasificación; la versión con cobertura se conserva como robustez y no altera la relevancia del estado laboral previo.

1.1 Muestra longitudinal y persistencia

Para incorporar la condición laboral del año anterior se realiza un inner join 2024–2025 sobre CODUSU + NRO_HOGAR + COMPONENTE, validado como one_to_one. Se obtienen 4.819 coincidencias y 4.714 casos con X completa, equivalentes al 33,8% de los asalariados clasificables de 2025. La tasa es inferior a la referencia general del 50% de rotación de la EPH porque la muestra analítica exige, además, permanecer en el universo de asalariados clasificables y contar con información completa.

ESTADO 2024	FORMAL 2025	INFORMAL 2025	TOTAL	% FORMAL 2025	% INFORMAL 2025
Formal	3.117	200	3.317	94,0%	6,0%
Informal	238	1.159	1.397	17,0%	83,0%
Total	3.355	1.359	4.714	71,2%	28,8%

Tabla 1. Transiciones de la condición de informalidad, muestra longitudinal 2024T4–2025T4 (N=4.714). Porcentajes condicionados al estado de 2024. Fuente: elaboración propia sobre EPH-INDEC.

La persistencia es elevada: 94% de quienes eran formales en 2024 continúa siéndolo en 2025 y 83% de los informales permanece en esa condición. Este patrón justifica incorporar el estado previo como predictor. La submuestra longitudinal, sin embargo, es menos informal que la muestra completa de 2025 (28,8% vs. 36,8%); por ello, las métricas posteriores describen el panel observado y no toda la población asalariada de 2025.

1.2 Comparabilidad entre entrenamiento y testeo

CARACTERÍSTICA	MEDIA 2024	MEDIA 2025	DIFERENCIA	DIF. %	T (WELCH)	P-VALOR
Edad (años)	40,025	40,485	0,460	1,15%	3,113	0,0019***
Edad ²	1.757,469	1.798,351	40,882	2,33%	3,241	0,0012***
Años de educación	12,195	12,196	0,001	0,01%	0,016	0,9876
Horas trabajadas	37,505	37,682	0,177	0,47%	0,957	0,3385
Integrantes del hogar	3,570	3,539	–0,031	–0,85%	–1,455	0,1456
Mujer (proporción)	0,471	0,473	0,002	0,42%	0,339	0,7348

Tabla 2. Balance Table, train 2024 vs. test 2025. Test t de Welch; *** p<0,01.

La Balance Table muestra que train y test son muy similares en las covariables observadas. Sólo edad y edad² presentan diferencias estadísticamente significativas, pero la magnitud económica es mínima: la edad promedio aumenta apenas 0,46 años. Por eso no observamos un cambio sustantivo de composición entre 2024 y 2025.

2. Modelos Logit y resultados (Sección B)

Se estiman por máxima verosimilitud dos modelos. El Modelo 1 utiliza la muestra de 2024 y seis características observables; el Modelo MM se estima sobre la muestra longitudinal de 2025 e incorpora adicionalmente `informal_2024`, siguiendo a Maurizio y Monsalvo (2021).

$$\text{Modelo 1: } \text{logit } P(I_{(2024)}=1 | X) = \alpha + X\beta$$

$$\text{Modelo MM: } \text{logit } P(I_{(2025)}=1 | X, I_{(2024)}) = \alpha + X\beta + \gamma \cdot I_{(2024)}$$

2.1 Estimación y odds ratios

CARACTERÍSTICA	M1 COEF.	EE	OR	MM COEF.	EE	OR
Edad	-0,2317***	0,0096	0,793	-0,1103***	0,0269	0,896
Edad ²	0,0022***	0,0001	1,002	0,0010***	0,0003	1,001
Años de educación	-0,2100***	0,0060	0,811	-0,1343***	0,0155	0,874
Horas trabajadas	-0,0244***	0,0013	0,976	-0,0188***	0,0035	0,981
Integrantes del hogar	0,1004***	0,0110	1,106	0,0950***	0,0290	1,100
Mujer	0,3730***	0,0412	1,452	0,1730	0,1116	1,189
Informal en 2024	—	—	—	3,9649***	0,1056	52,712
Pseudo r ²	0,178			0,538		

Tabla 3. Modelos Logit. Variable dependiente: informal=1. Se omite la constante. *** p<0,01. Especificación principal sin cobertura médica.

El principal resultado es la fuerte persistencia de la informalidad. En el Modelo 1, educación, edad, horas trabajadas, tamaño del hogar y sexo presentan asociaciones significativas con la condición informal. Al incorporar el estado laboral de 2024, esos coeficientes se atenúan y la informalidad previa se convierte en el predictor dominante, con un odds ratio cercano a 52,7. Esto indica que la trayectoria laboral contiene una gran cantidad de información predictiva adicional, aunque el resultado no tiene una interpretación causal.

2.2 Efectos marginales promedio

CARACTERÍSTICA	AME M1	AME MM	LECTURA
Años de educación	-0,0378	-0,0104	-3,8 pp por año en M1; -1,0 pp en MM
Horas trabajadas	-0,0044	-0,0015	-0,44 pp por hora en M1; -0,15 pp en MM
Integrantes del hogar	0,0181	0,0074	+1,8 pp por integrante; +0,7 pp en MM
Mujer	0,0672	0,0135 (n.s.)	+6,7 pp vs. varón en M1
Informal en 2024	—	0,6800	+68 pp vs. formal en 2024
Edad — efecto total	-0,0103	-0,0024	-1,03 pp/año en M1; -0,24 pp en MM

Tabla 4. Efectos marginales promedio. Para las variables continuas se reportan AME; para las variables binarias, el cambio discreto de 0 a 1. El efecto de edad considera conjuntamente edad y edad². Fuente: elaboración propia sobre EPH-INDEC.

La incorporación del estado laboral previo modifica sustancialmente la importancia relativa de los predictores. Haber sido informal en 2024 se asocia con un aumento promedio de **68 p.p.** en la probabilidad predicha de informalidad en 2025. Al mismo tiempo, los efectos asociados a educación, edad, horas trabajadas y tamaño del hogar se atenúan, lo que evidencia el fuerte contenido predictivo de la trayectoria laboral previa.

2.3 Probabilidad predicha sobre 2025




Figura 1. Probabilidad predicha promedio de informalidad en 2025 según años de educación. Predicciones construidas con los coeficientes del Modelo 1 estimado en 2024.


La probabilidad predicha promedio de informalidad disminuye marcadamente con la educación: supera el 80% en los niveles educativos más bajos y cae por debajo del 25% luego de completar el secundario. Las oscilaciones locales responden a que cada punto promedia individuos con distintas características observables; por lo tanto, el gráfico no representa un efecto causal de la escolaridad.

3. Desempeño predictivo y decisión de política (Sección C)

Ambos modelos se comparan sobre las mismas 4.714 observaciones longitudinales, usando el umbral $p > 0,5$. Dado que $\text{informal} = 1$, el recall mide la proporción de informales reales detectados y la precision mide cuántos de los señalados como informales efectivamente lo son. La AUC resume la capacidad de discriminación a través de todos los umbrales posibles.

Incorporar el estado previo reduce los informales no detectados de 695 a 204

Umbral $p > 0,5$ · Informal = 1 · N = 4.714



Fuente: elaboración propia sobre EPH-INDEC, 4T2024 y 4T2025.


Figura 2. Matrices de confusión de los modelos de clasificación, umbral $p > 0,5$. Cada celda reporta el número de observaciones y su proporción dentro de la categoría observada. En el Modelo 1 se registran 695 falsos negativos y 392 falsos positivos; en el Modelo MM, 204 y 233, respectivamente. El Modelo MM se estima y evalúa sobre la

misma submuestra longitudinal, por lo que sus métricas deben interpretarse con la salvedad de ajuste dentro de muestra.

MODELO	ACCURACY	PRECISION	RECALL	F1	AUC	FPR	FNR
Modelo 1	0,769	0,629	0,489	0,550	0,782	0,117	0,511
Modelo MM	0,907	0,832	0,850	0,841	0,928	0,069	0,150

Tabla 5. Desempeño de los modelos de clasificación sobre la muestra longitudinal (N = 4.714). Se reportan accuracy, precisión, recall, F1, AUC, tasa de falsos positivos (FPR) y tasa de falsos negativos (FNR), utilizando un umbral de clasificación de $p > 0,5$.

El Modelo 1 supera al clasificador trivial —que alcanzaría una accuracy de 71,2% prediciendo “formal” para todos—, pero su recall de 48,9% implica que no detecta a más de la mitad de los trabajadores informales. En la evaluación realizada, el Modelo MM presenta mejores resultados en todas las métricas: el recall aumenta a 85,0%, la precisión a 83,2% y el AUC a 0,928, mientras que la tasa de falsos negativos cae de 51,1% a 15,0%.



Fuente: elaboración propia sobre EPH-INDEC.

Nota: una curva más próxima al vértice superior izquierdo indica mayor capacidad de discriminación. La evaluación del Modelo MM tiene un componente in-sample.

Figura 3. Curvas ROC de ambos modelos frente al clasificador aleatorio. Fuente: elaboración propia sobre EPH-INDEC.

Salvedad de validación. El Modelo 1 se estima con 2024 y se evalúa en 2025, por lo que su desempeño es temporalmente fuera de muestra. El Modelo MM se estima y evalúa sobre la submuestra longitudinal de 2025; sus métricas contienen un componente in-sample y pueden resultar optimistas respecto de datos nuevos. Una validación estrictamente comparable requeriría una ventana temporal adicional. Las métricas no utilizan PONDERA.

3.1 Criterio de política: Errores tipo I y II

Con $\text{informal}=1$, un falso positivo es un trabajador formal clasificado como informal: consume recursos destinados al grupo objetivo. Un falso negativo es un trabajador informal clasificado como formal: queda fuera una persona potencialmente destinataria. Bajo $p > 0,5$, el Modelo MM reduce los falsos negativos 71% ($695 \rightarrow 204$) y los falsos positivos 41% ($392 \rightarrow 233$). Por ello, dentro de la evaluación realizada, combina mejor cobertura (recall) y focalización (precisión).

La recomendación tiene una restricción operativa: el Modelo MM requiere conocer la condición laboral previa. En una aplicación real, esa información debería provenir de registros administrativos longitudinales; la EPH permite evaluar la lógica predictiva del enfoque, pero no constituye por sí misma un instrumento operativo de focalización individual. Para personas sin historial observable, el Modelo 1 funciona como alternativa de primera línea y podría emplear un umbral inferior a 0,5 si la prioridad de política fuese minimizar omisiones.

4. Conclusiones

Los resultados de TP2 y TP3 son complementarios. El análisis no supervisado del TP2 mostró que la dicotomía formal/informal no emerge espontáneamente como una partición natural de las características observadas. El TP3 muestra, sin embargo, que la condición sí presenta capacidad predictiva cuando se aborda de manera supervisada: el Modelo 1 alcanza $AUC=0,782$, aunque con sensibilidad limitada al umbral de 0,5.

La principal ganancia proviene de incorporar la trayectoria laboral. En la muestra longitudinal, 83% de los informales de 2024 permanece informal en 2025; consistentemente, `informal_2024` presenta $OR=52,7$ y un efecto marginal promedio cercano a +68 pp. En la evaluación solicitada, el modelo con estado previo exhibe $AUC=0,928$ y $recall=0,850$, con la salvedad de que estas métricas contienen ajuste dentro de muestra.

En términos de política, el hallazgo sugiere que la historia laboral contiene información especialmente relevante para identificar situaciones persistentes de informalidad. No obstante, esta evidencia es predictiva y no causal: para determinar qué intervenciones generan formalización sería necesaria una estrategia de identificación adicional.

5. Uso de herramientas de IA

Se utilizó Copilot como herramientas de apoyo a la organización del notebook, revisión de código, reconstrucción de variables, auditoría metodológica e interpretación de Logit, efectos marginales y métricas de clasificación.

Tiempo total aproximado dedicado al TP: 10hs

Referencias

Maurizio, R. y Monsalvo, A. P. (2021). Informality, labour transitions, and the livelihoods of workers in Latin America. WIDER Working Paper 2021/19, UNU-WIDER.

INDEC. Encuesta Permanente de Hogares, bases usuarias individuales, 4° trimestre de 2024 y 4° trimestre de 2025.