

Clasificando informales en la EPH: métodos de regularización y CART

Estefanía Embarbe · Grupo 1 · Universidad de Buenos Aires · Taller de Programación · 2026

Repositorio GitHub:

<https://github.com/embarbeestefania-code/Taller Programacion EPH/tree/main/TP4 Entrega>

Datos, objetivo y estrategia empírica

El objetivo es predecir la informalidad laboral en 2025 y comparar el desempeño de cuatro especificaciones: una regresión logística sin penalización, regresiones logísticas penalizadas mediante LASSO (L1) y Ridge (L2), y un árbol de clasificación CART. La variable objetivo ***informal_2025*** toma valor 1 para los asalariados sin descuento jubilatorio (PP07H=2) y 0 para aquellos con descuento (PP07H=1).

La muestra modelable final contiene 4.819 observaciones longitudinales correspondientes a trabajadores observados en 2024–2025. La especificación utiliza 23 predictores. Luego de transformar las variables categóricas en variables indicadoras, la matriz de diseño contiene 75 columnas.

Para evitar *data leakage*, las imputaciones de valores faltantes se realizan exclusivamente con información del conjunto de entrenamiento dentro de cada *fold* de validación cruzada. Asimismo, se excluyen de la matriz de predictor variables como, PP07H, EMPLEO, SECTOR y CH08, por estar directamente relacionadas con la definición. La variable *informal_2025* se utiliza exclusivamente como variable objetivo.

En la muestra longitudinal final, el **29,28%** de los trabajadores asalariados son informales en 2025, proporción que se tendrá en cuenta al evaluar las métricas de clasificación.

Construcción de predictores

La matriz se construyó con variables de interpretación directa para la informalidad laboral. Se conservó ***educ*** en años de educación —creada en el TP2— y no se incorporaron simultáneamente dummies de nivel educativo para evitar redundancia. Los predictores se agrupan en siete dimensiones: **capital humano y hogar** (edad, edad², educación y tamaño del hogar); **inserción e intensidad laboral** (horas, pluriempleo, deseo y búsqueda de más horas, búsqueda de otro empleo e intensidad); **puesto y establecimiento** (tipo y tamaño); **estabilidad** (antigüedad y duración del empleo); **estructura productiva** (rama CAES, grupo ocupacional CNO y calificación); **posición socioeconómica** (decil de ingreso laboral); y **demografía y territorio** (sexo, migración, región y tamaño del aglomerado). A estas características contemporáneas se incorpora *informal_2024* como predictor histórico.

A. Modelo de Regresión logística con regularización: LASSO y RIDGE

A.1. Trayectorias de coeficientes

Se estimaron modelos de regresión logística penalizados mediante LASSO (L1) y Ridge (L2) para distintos niveles de regularización, definiendo $\lambda = 1/C$ y considerando $\lambda = 10^n$, con $n \in \{-5, \dots, 5\}$. De este modo, valores mayores de λ representan una penalización más intensa. A medida que aumenta la penalización, ambos métodos contraen la magnitud de los coeficientes. Sin embargo, LASSO puede llevar coeficientes exactamente a cero y, por lo tanto, realizar selección de variables, mientras que Ridge mantiene todos los predictores con coeficientes progresivamente más pequeños.

En LASSO, la cantidad de coeficientes nulos aumenta de 2 sobre 75 para $\lambda = 0,1$ a 9 para $\lambda = 1$, 22 para $\lambda = 10$, 64 para $\lambda = 100$ y 74 para $\lambda = 1.000$. Para valores de $\lambda \geq 10^4$, todos los coeficientes quedan anulados. En contraste, Ridge reduce progresivamente su magnitud sin producir selección exacta.

Entre los predictores, *informal_2024* presenta una de las trayectorias de mayor magnitud y persistencia frente al aumento de la penalización, lo que sugiere una fuerte capacidad predictiva de la situación de informalidad previa sobre la condición observada en 2025.




Figura 1. Trayectorias de coeficientes estandarizados para LASSO y Ridge. Se destaca *informal_2024*.

A.2. Selección de la penalización mediante validación cruzada

El nivel óptimo de regularización de los modelos LASSO y Ridge se seleccionó mediante **validación cruzada de 5 folds**. Para evitar filtración de información (*data leakage*), las etapas de imputación, codificación de variables categóricas y estandarización se realizaron dentro de cada fold, utilizando exclusivamente la información correspondiente al conjunto de entrenamiento.

Como criterio de evaluación se utilizó el error de clasificación, definido como $1 - \text{accuracy}$. La validación cruzada seleccionó $\lambda = 0,1 (C = 10)$ para LASSO y $\lambda = 10 (C = 0,1)$ para Ridge.

Ambos modelos alcanzaron un error medio de validación cruzada de **0,08342**, equivalente a una accuracy media de **0,91658**. Por lo tanto, las diferencias de desempeño predictivo entre ambas especificaciones son prácticamente nulas según esta métrica.

	λ CV	C	ERROR CV	ACCURACY CV
LASSO	0,1	10	0,08342	0,91658
RIDGE	10	0,1	0,08342	0,91658




Figura 2. Distribución del error de validación por λ y penalidad (5 folds).

A.3. Estimación y Comparación de coeficientes

Con los niveles de penalización seleccionados por validación cruzada, **LASSO conserva 73 de las 75 columnas modelables**, anulando únicamente quiere_mas_horas y tipo_duracion_empleo_temporal, mientras que Ridge conserva todas. El predictor *informal_2024* presenta el coeficiente de mayor magnitud y se mantiene estable frente a la regularización (Logit = 1,4661; LASSO = 1,4658; Ridge = 1,4164), lo que evidencia una fuerte persistencia predictiva de la informalidad entre 2024 y 2025. La limitada selección de LASSO sugiere que una mayor reducción de predictores no mejora el desempeño clasificatorio. Otros coeficientes relevantes se vinculan con permanencia laboral, ingreso, tamaño del establecimiento, edad, intensidad y antigüedad. La tabla completa de coeficientes se presenta en el **Apéndice A**.

B. Árbol de clasificación CART

B.1. Selección de complejidad y poda

Se estimó un árbol de decisión y se eligió el parámetro de costo-complejidad mediante 5-fold cross-validation. El valor seleccionado fue $ccp_alpha=0,0014424$, con error medio de validación 0,09130 y accuracy media 0,90870. El árbol final estimado sobre la muestra completa tiene profundidad 4, 9 hojas y 17 nodos, manteniendo una representación parsimoniosa. Apéndice B. Matrices de confusión




Figura 3. Selección de ccp_alpha mediante 5-fold cross-validation.

B.2. Árbol podado e importancia de predictores

El nodo raíz divide por *informal_2024*: entre quienes eran formales en 2024, alrededor de 6% es informal en 2025; entre quienes eran informales en 2024, cerca de 83% continúa informal. La importancia de *informal_2024* alcanza 0,8906. Muy por detrás aparecen empleo permanente (0,0600), decil de ingreso (0,0296), tamaño del establecimiento de 2 a 5 personas (0,0080), construcción (0,0063) y edad² (0,0055).




Figura 4. CART podado e importancia de predictores.

La correspondencia entre CART y LASSO es parcial. Las dos columnas anuladas por LASSO también tienen importancia cero en CART, pero el árbol utiliza sólo seis columnas con importancia positiva y deja en cero muchas variables que LASSO conserva. La diferencia responde a que LASSO selecciona dentro de una estructura lineal aditiva, mientras CART construye reglas mediante umbrales e interacciones no lineales.

C. Comparación entre métodos

C.1. Desempeño predictivo

Los cuatro modelos se compararon con predicciones out-of-fold de 5 folds y umbral $p \geq 0,5$. Logit, LASSO y Ridge presentan errores cercanos a 8,3% y AUC superiores a 0,96; Ridge alcanza el mayor AUC (0,9647), mientras LASSO obtiene el mayor F1 entre los modelos logísticos (0,8566). CART tiene un error algo mayor (0,0909) y menor AUC (0,9422), pero alcanza el mayor recall (0,8795) y la menor cantidad de falsos negativos (170).

MODELO	VN	FP	FN	VP	ACC.	1-ACC.	PREC.	RECALL	F1	AUC
LOGIT	3216	192	212	1199	0,9162	0,0838	0,8620	0,8498	0,8558	0,9626
LASSO	3216	192	210	1201	0,9166	0,0834	0,8622	0,8512	0,8566	0,9627
RIDGE	3218	190	212	1199	0,9166	0,0834	0,8632	0,8498	0,8564	0,9647
CART	3140	268	170	1241	0,9091	0,0909	0,8224	0,8795	0,8500	0,9422




Figura 5. Curvas ROC out-of-fold para los cuatro modelos.

No se observa una ventaja general por utilizar un método no lineal: CART no supera a los modelos logísticos en capacidad discriminadora global. Sin embargo, al umbral 0,5 mejora la detección de informales, a costa de más falsos positivos. La comparación ilustra el trade-off entre performance global, focalización e interpretabilidad.

C.1.b. Desempeño en GBA

En GBA se evalúan 626 observaciones longitudinales, con 168 informales (26,84%). Se reproduce el trade-off del total de la muestra: Ridge presenta el mayor AUC regional (0,9374), mientras CART alcanza el mayor recall (0,8155), el mayor F1 (0,7851), la mayor accuracy (0,8802) y reduce los falsos negativos a 31. Por lo tanto, la ventaja de CART para minimizar omisiones de informales también se mantiene en la evaluación regional.

C.2. Selección del modelo para política pública

Para la Secretaría de Trabajo, un falso negativo corresponde a un trabajador informal que no es identificado; un falso positivo implica asignar recursos a un trabajador formal. Si el costo social de omitir a un informal es mayor que el costo de incorporar erróneamente a un formal, CART resulta atractivo: reduce los falsos negativos a 170 y alcanza recall=0,8795, aunque eleva los falsos positivos a 268. Si la restricción presupuestaria penaliza más los falsos positivos, LASSO/Ridge ofrecen un mejor desempeño global.

Conclusiones

Los resultados muestran una fuerte persistencia de la informalidad: *informal_2024* domina los modelos logísticos y explica 89,1% de la importancia del CART. La matriz ampliada aporta información adicional vinculada con estabilidad contractual, ingreso, tamaño del establecimiento, rama y edad. La regularización no mejora de manera sustantiva al Logit sin penalización y, en el λ CV de LASSO, la selección es mínima. CART sacrifica algo de AUC y accuracy, pero maximiza el recall y ofrece reglas de clasificación fáciles de comunicar. La evidencia es predictiva, no causal.

Como limitación, la comparación se realiza sobre la muestra longitudinal disponible y no sobre un test externo independiente. Además, la no respuesta de ingreso requiere imputación, realizada dentro de cada fold. Una validación con un tercer período o nested cross-validation permitiría evaluar con mayor rigor la generalización de los hiperparámetros seleccionados.

D. Herramientas de IA y reflexión final

Se utilizaron Copilot y Gemini integrado a Colab como apoyo para ordenar la secuencia del trabajo, reconstruir y auditar variables de la EPH, detectar riesgo de target leakage, depurar código e interpretar regularización, CART y métricas de clasificación. La IA fue útil para estructurar el flujo de programación y contrastar resultados; la lectura de códigos específicos de la EPH y las decisiones metodológicas se verificaron contra la documentación y las salidas efectivamente obtenidas.

Referencias

INDEC. Encuesta Permanente de Hogares (EPH), bases usuarias individuales, 4° trimestre de 2024 y 2025.
Maurizio, R. y Monsalvo, A. P. (2021). Informality, labour transitions, and the livelihoods of workers in Latin America. WIDER Working Paper 2021/19, UNU-WIDER.

Apéndice A. Coeficientes: Logit, LASSO y Ridge

Coeficientes estimados sobre predictores estandarizados. $\lambda_{CV}=0,1$ para LASSO y $\lambda_{CV}=10$ para Ridge. La tabla corresponde a las 75 columnas modelables luego del one-hot encoding.

VARIABLE	LOGIT	LASSO (L1)	RIDGE (L2)
Informal_2024	1.4661	1.4658	1.4164
Tam_Establecimiento_No_Aplica	-1.2128	-1.1409	-0.1655
Tipo_Duracion_Empleo_Permanente	-0.7154	-0.9726	-0.4848
Decil_Ingreso	-0.7714	-0.7714	-0.7290
Tam_Establecimiento_2a5	0.6953	0.6927	0.6004
Edad	-0.6484	-0.5681	-0.2067
Intensidad_Sobreocupado	0.6035	0.5637	0.1873
Intensidad_Plano	0.5787	0.5410	0.1625
Antiguedad_No_Aplica	0.7162	0.5157	0.2100
Edad2	0.5746	0.4945	0.1347
Antiguedad_Mas_5_Anios	-0.4646	-0.4551	-0.3686
Tam_Establecimiento_Sin_Info	0.4111	0.4098	0.3251
Tam_Establecimiento_6a10	0.3970	0.3945	0.3178
Intensidad_Subocupado	0.3956	0.3778	0.1751
Tipo_Establecimiento_Privado	0.3355	0.3529	0.3230
Rama_Sector_Finanzas	-0.3115	-0.3155	-0.2625
Rama_Sector_Servicio_Domestico	0.3643	0.2947	-0.0256
Tam_Establecimiento_11a40	0.2932	0.2903	0.1973
Grupo_Ocupacional_Gestion_Administrativa_Legal	-0.2876	-0.2824	-0.2275
Calificacion_Ocupacional_Profesional	0.2723	0.2673	0.2224
Rama_Sector_Educacion	-0.2463	-0.2613	-0.2156
Region_Pampeana	-0.2610	-0.2572	-0.2036
Region_Patagonia	-0.2484	-0.2462	-0.2033
Tipo_Establecimiento_Otro	0.2347	0.2382	0.2178
Calificacion_Ocupacional_Sin_Info	-0.2420	-0.2363	-0.1526
Antiguedad_6a12_Meses	-0.2319	-0.2266	-0.1802
Rama_Sector_Agro_Pesca	0.2279	0.2208	0.2122
Region_Noa	-0.2168	-0.2124	-0.1645
Rama_Sector_Sin_Info	-0.2661	-0.1935	-0.1107
Grupo_Ocupacional_Servicios_Sociales_Basicos	-0.1736	-0.1644	-0.1202
Rama_Sector_Construccion	0.1803	0.1642	0.1621
Rama_Sector_Transporte	0.1715	0.1602	0.1747
Antiguedad_1a5_Anios	-0.1677	-0.1573	-0.0772
Educ	-0.1551	-0.1558	-0.1487
Grupo_Ocupacional_Produccion_Agropecuaria	-0.1552	-0.1534	-0.1245
Rama_Sector_Energia	-0.1489	-0.1522	-0.1286
Grupo_Ocupacional_Servicios_Varios	-0.1562	-0.1508	-0.1228
Rama_Sector_Profesionales_Tecnicas	0.1538	0.1463	0.1585
Horas_Totales	-0.1525	-0.1455	-0.1039
Region_Nea	-0.1415	-0.1398	-0.0997
Rama_Sector_Salud_Servicios_Sociales	0.1460	0.1306	0.1298
Rama_Sector_Administrativas_Apoyo	-0.1121	-0.1234	-0.1016
Region_Gba	-0.1194	-0.1161	-0.0814
Grupo_Ocupacional_Gestion_Financiera_Contable	-0.1135	-0.1105	-0.0914
Busco_Otro_Empleo	0.1076	0.1080	0.0983
Rama_Sector_Organismos_Extraterritoriales	-0.1015	-0.1055	-0.0844
Nhogar	0.0983	0.0968	0.0961

<i>Rama_Sector_Arte_Recreacion</i>	0.0973	0.0909	0.1049
<i>Busco_Mas_Horas</i>	0.0879	0.0837	0.0765
<i>Aglomerado_Grande</i>	0.0817	0.0815	0.0810
<i>Pluriempleo</i>	0.0817	0.0812	0.0715
<i>Rama_Sector_Industria</i>	-0.0499	-0.0656	-0.0408
<i>Tipo_Duracion_Empleo_Sin_Info</i>	0.2018	0.0610	0.2983
<i>Rama_Sector_Informacion_Comunicaciones</i>	0.0665	0.0576	0.0656
<i>Grupo_Ocupacional_Direccion</i>	-0.0579	-0.0556	-0.0458
<i>Rama_Sector_Mineria</i>	0.0544	0.0463	0.0300
<i>Mujer</i>	0.0480	0.0459	0.0382
<i>Antiguedad_Menos_1_Mes</i>	-0.0462	-0.0447	-0.0258
<i>Rama_Sector_Agua_Saneamiento</i>	0.0467	0.0430	0.0447
<i>Calificacion_Ocupacional_Tecnica</i>	-0.0319	-0.0351	-0.0625
<i>Grupo_Ocupacional_Extractiva_Energia_Construccion</i>	0.0304	0.0341	0.0665
<i>Rama_Sector_Alojamiento_Comidas</i>	-0.0196	-0.0304	0.0016
<i>Tam_Establecimiento_1_Persona</i>	0.0278	0.0286	0.0827
<i>Antiguedad_3a6_Meses</i>	-0.0323	-0.0282	0.0005
<i>Rama_Sector_Otros_Servicios</i>	0.0356	0.0282	0.0423
<i>Tam_Establecimiento_41a100</i>	0.0308	0.0272	-0.0389
<i>Calificacion_Ocupacional_Operativa</i>	0.0221	0.0162	-0.0104
<i>Rama_Sector_Comercio</i>	0.0017	-0.0151	0.0383
<i>Antiguedad_Sin_Info</i>	-0.0095	-0.0084	-0.0025
<i>Rama_Sector_Inmobiliarias</i>	0.0094	0.0058	0.0155
<i>Grupo_Ocupacional_Instalacion_Mantenimiento_Tecnologia</i>	-0.0059	-0.0039	0.0067
<i>Migrante</i>	-0.0043	-0.0037	-0.0049
<i>Grupo_Ocupacional_Industria_Reparacion</i>	-0.0058	-0.0019	0.0156
<i>Quiere_Mas_Horas</i>	-0.0035	0.0000	0.0138
<i>Tipo_Duracion_Empleo_Temporal</i>	0.1610	0.0000	0.2792

Apéndice B. Matrices de confusión

Matrices de confusión — umbral $p \geq 0,5$




Figura B.1. Matrices de confusión out-of-fold, umbral $p \geq 0,5$.